

Modelado Espacio-Temporal Jerárquico Bayesiano de la Respuesta del Rendimiento de Quinua (*Chenopodium quinoa* Willd.) a la Variabilidad Agroclimática en el Altiplano de Puno, Perú (2010–2025)

Primer Autor, Segundo Autor, y Tercer Autor

Resumen—La quinua (*Chenopodium quinoa* Willd.) es el cultivo de grano andino más importante de la región Puno (Perú), la cual concentra más del 70 % de la producción nacional peruana. El rendimiento de la quinua exhibe una alta variabilidad interanual impulsada por el complejo régimen agroclimático de esta meseta de gran altitud. Este estudio desarrolla un modelo espacio-temporal jerárquico bayesiano para cuantificar los efectos simultáneos de cuatro variables agroclimáticas de la API NASA POWER sobre el rendimiento distrital de quinua a lo largo de 15 campañas agrícolas (2010–2025).

Se integraron datos de rendimiento distrital (kg/ha) de 86 distritos de la región Puno ($N = 1267$ observaciones) con variables agroclimáticas de NASA POWER: precipitación total corregida (PRECTOTCORR), temperatura mínima del aire (T2M_MIN), humedad relativa (RH2M) e irradiancia de onda corta incidente en superficie (ALLSKY_SFC_SW_DWN). Se especificó un modelo jerárquico bayesiano compuesto por: (i) efectos fijos para las variables agroclimáticas y de control; (ii) un efecto espacial aleatorio estructurado de tipo Besag-York-Mollié 2 (BYM2) con vecindad de 5 vecinos más cercanos ($k = 5$); y (iii) un efecto temporal aleatorio autorregresivo de primer orden AR(1). La inferencia se realizó mediante la Aproximación de Laplace Anidada Integrada (INLA) con distribuciones previas de complejidad penalizada (PC).

El modelo jerárquico completo (M3) superó a las alternativas anidadas según los criterios WAIC, DIC y log-CPO. La precipitación estacional ejerció un efecto positivo significativo sobre el rendimiento ($\hat{\beta}_1 = 120.5$ kg/ha por desviación estándar, equivalente a $+0.668$ kg/ha por cada milímetro adicional; IC del 95 %: [85.2, 155.8]). La temperatura mínima mostró un efecto positivo significativo de 95.3 kg/ha por DE (IC del 95 %: [60.1, 130.5]), lo que indica que temperaturas mínimas más cálidas benefician al rendimiento al reducir el daño por heladas. La humedad relativa tuvo un efecto negativo significativo (-65.4 kg/ha por DE; IC del 95 %: $[-100.2, -30.6]$), coherente con una mayor presión de patógenos (mildiu, *Peronospora farinosa*) bajo condiciones húmedas. El componente espacial BYM2 demostró que la estructura espacial explica una fracción importante de la varianza residual ($\hat{\phi} = 0.724$; IC del 95 %: [0.551, 0.852]), identificando un déficit sistemático de rendimiento en los distritos de

mayor altitud y menor termorregulación. El coeficiente temporal AR(1) $\hat{\rho} = 0.452$ (IC del 95 %: [0.153, 0.721]) capturó la dinámica interanual modulada por eventos ENSO. Un escenario de calentamiento de $+2^\circ\text{C}$ proyecta un incremento medio en el rendimiento de 80.4 kg/ha (7.5 %; IC del 95 %: [50.7, 110.2] kg/ha) debido a la reducción de heladas, asumiendo disponibilidad de agua.

El modelado jerárquico bayesiano reveló una heterogeneidad agroclimática significativa en el rendimiento de la quinua en el altiplano de Puno a escala distrital, evidenciando un claro impacto del Problema de la Unidad de Área Modificable (MAUP) en comparación con agregaciones mayores. Se recomiendan intervenciones focalizadas en los distritos con desventajas espaciales y estrategias de adaptación agrícola alineadas con los pronósticos de ENSO.

Index Terms—*Chenopodium quinoa*, Modelo jerárquico bayesiano, Efecto espacial BYM2, Autocorrelación temporal AR(1), INLA, NASA POWER, Altiplano, Variabilidad climática, Modelado de rendimiento agrícola.

I. INTRODUCCIÓN

La quinua (*Chenopodium quinoa* Willd.) es un pseudocereal nativo de las tierras altas andinas de América del Sur y es ampliamente reconocida como uno de los alimentos vegetales más completos nutricionalmente, conteniendo todos los aminoácidos esenciales con un contenido proteico que oscila entre el 14 % y el 22 % en peso seco [1]. A nivel mundial, la quinua ha experimentado una rápida expansión global debido a su alta plasticidad ecológica y diversidad genética [2]. El altiplano peruano, particularmente la región de Puno situada entre los 3,800 y 4,200 metros sobre el nivel del mar (m.s.n.m.) a lo largo de las orillas del Lago Titicaca ($14^\circ\text{--}17^\circ\text{S}$; $68^\circ\text{--}71^\circ\text{O}$), constituye el principal centro de diversidad de esta especie y representa aproximadamente el 70–75 % de la producción total de quinua en el Perú [3], [4], donde se cultivan numerosas variedades comerciales y nativas adaptadas a diferentes ecorregiones [5].

A pesar de su importancia cultural y económica, el rendimiento de la quinua en Puno exhibe una marcada variabilidad interanual y espacial, que típicamente

Primer Autor y Segundo Autor están con la Universidad Nacional del Altiplano, Facultad de Ingeniería Estadística e Informática, Av. Floral 1153, Puno 21001, Perú (correo electrónico: primer.autor@universidad.edu.pe).

Tercer Autor está con [Institución 2], [Ciudad, País].

oscila entre 320 y 1,595 kg/ha a nivel distrital [4], condicionando la estabilidad del rendimiento y la respuesta adaptativa del cultivo bajo la interacción genotipo-ambiente [6]. Esta variabilidad está fundamentalmente impulsada por el complejo régimen agroclimático del altiplano: (1) un patrón de precipitación altamente estacional concentrado entre octubre y marzo ($> 80\%$ de la precipitación anual); (2) la ocurrencia frecuente de heladas (temperaturas mínimas inferiores a 0°C), particularmente durante la temporada de crecimiento (noviembre–febrero); (3) una intensa radiación solar debido a la delgada atmósfera de gran altitud; y (4) marcados gradientes espaciales de temperatura y precipitación relacionados con la topografía y la proximidad al Lago Titicaca [7], [8].

Estudios previos han documentado relaciones significativas entre variables agroclimáticas individuales y el rendimiento de la quinua, influenciadas por el fotoperíodo, la radiación solar y la temperatura [9]–[12]. Sin embargo, la cuantificación simultánea de múltiples factores agroclimáticos a lo largo del heterogéneo paisaje distrital de Puno sigue siendo un desafío metodológico por tres razones. Primero, la estructura espacial de los distritos productores induce autocorrelación espacial en los residuos del rendimiento, violando los supuestos de independencia de los modelos de regresión estándar [13]. Segundo, la naturaleza de panel de los datos (distritos $\times$ campañas) requiere controlar la heterogeneidad no observada entre distritos y la correlación temporal. Tercero, las variables agroclimáticas como la precipitación y la temperatura mínima están correlacionadas espacial y temporalmente, lo que plantea desafíos de colinealidad en la inferencia clásica.

Los modelos jerárquicos bayesianos ofrecen un marco integrado para abordar estos desafíos de manera simultánea [14]. En las ciencias agrícolas, se han aplicado con éxito para modelar la variabilidad del rendimiento de los cultivos en el contexto del cambio climático [15]–[17], incluyendo desarrollos recientes en modelos bayesianos con coeficientes espacialmente variantes [18] y en la cuantificación de los impactos del cambio climático sobre la producción de cultivos alimenticios clave [19]. El modelado de la variabilidad espacio-temporal del rendimiento permite evaluar la incertidumbre predictiva en comparación con modelos basados en procesos o algoritmos de aprendizaje automático [20]. El modelo de Besag-York-Mollié (BYM) y su reparametrización BYM2 [21] brindan un enfoque fundamentado para los efectos espaciales aleatorios, mientras que el proceso autorregresivo de primer orden AR(1) captura la dinámica temporal. La Aproximación de Laplace Anidada Integrada (INLA) [22], [23] permite realizar inferencia bayesiana eficiente para estos modelos, haciéndolos viables para grandes conjuntos de datos agrícolas.

Hasta donde tenemos conocimiento, ningún estudio previo ha aplicado un modelo espacio-temporal jerár-

quico bayesiano conjunto al rendimiento de quinua a nivel distrital en toda la región Puno, integrando variables agroclimáticas de NASA POWER durante un periodo de 15 años. Este estudio aborda esta brecha en la literatura.

Los objetivos de este estudio son: (1) cuantificar los efectos de variables agroclimáticas clave (precipitación, temperatura mínima, humedad relativa y radiación solar) sobre el rendimiento de quinua en los distritos productores de Puno (2010–2025); (2) identificar patrones espaciales de heterogeneidad residual no explicados por factores agroclimáticos; (3) caracterizar la dinámica temporal interanual en el rendimiento; y (4) estimar el impacto potencial de escenarios de calentamiento global sobre el rendimiento de quinua en el altiplano, analizando críticamente el efecto de la escala mediante la comparación espacio-temporal.

I-A. Problema Científico

¿Cómo determinan conjuntamente las variables agroclimáticas (PRECTOTCORR, T2M_MIN, RH2M, ALLSKY_SFC_SW_DWN) la variabilidad espacial y temporal del rendimiento de quinua (kg/ha) en los distritos del altiplano de Puno (2010–2025), después de controlar por superficie sembrada y precio chacra, al tiempo que se considera la heterogeneidad espacial no observada (BYM2) y la autocorrelación temporal (AR1)?

I-B. Hipótesis

- H₁** La precipitación total corregida durante la temporada de crecimiento tiene un efecto positivo en el rendimiento de la quinua, con rendimientos decrecientes o estabilización en niveles altos.
- H₂** La temperatura mínima muestra una relación positiva en el rango observado en el altiplano; valores por debajo de 0°C (heladas) provocan pérdidas significativas de rendimiento.
- H₃** La humedad relativa ejerce un efecto negativo sobre el rendimiento a valores elevados ($> 70\%$), lo que refleja una mayor presión de enfermedades fúngicas (mildiu, *Peronospora farinosa*).
- H₄** La radiación solar afecta positivamente al rendimiento mediante una mayor asimilación fotosintética de carbono.
- H₅** Existe una autocorrelación espacial residual en el rendimiento que puede representarse mediante un efecto espacial estructurado para capturar heterogeneidades locales no observadas.
- H₆** Una autocorrelación temporal AR(1) significativa ($|\rho| > 0.3$) refleja la persistencia de la variabilidad interanual asociada al ciclo ENSO en el altiplano de Puno.

II. MATERIALES Y MÉTODOS

II-A. Área de Estudio

El área de estudio abarca la región de Puno (14° – 17°S ; 68° – 71°O), ubicada en el sureste de los Andes

del Perú, con altitudes que varían entre los 3,800 y 5,000 m.s.n.m. La región comprende 13 provincias y 110 distritos (de los cuales 86 distritos son productores activos de quinua analizados en este estudio), cubriendo aproximadamente 71,999 km². El clima se clasifica como BWk (semiárido frío, clasificación de Köppen) a ET (tundra polar) a lo largo de los gradientes altitudinales. La precipitación anual varía desde 350 mm en la puna sur hasta más de 800 mm en los sectores del norte y oeste adyacentes al Lago Titicaca. La campaña agrícola se desarrolla principalmente de octubre a abril, estableciéndose la siembra de quinua predominantemente entre octubre y diciembre.

II-B. Fuentes de Datos

II-B1. Estadísticas Agrícolas (MIDAGRI): Los datos agrícolas a nivel distrital se extrajeron de la base de datos oficial consolidada por las Agencias Agrarias de la Dirección Regional Agraria de Puno (DRAP) y las Hojas de Seguimiento Agrícola (SH) publicadas por el Ministerio de Desarrollo Agrario y Riego (MIDAGRI) para las campañas 2010–2011 a 2024–2025. Los documentos fueron digitalizados y estructurados en un panel balanceado utilizando técnicas automatizadas de extracción de texto en formato PDF [24]. Los datos obtenidos a nivel distrital incluyen: (1) superficie sembrada (ha), (2) superficie cosechada (ha), (3) producción total (t), (4) rendimiento (kg/ha) y (5) precio chacra (\$/kg).

II-B2. Variables Agroclimáticas (NASA POWER): Se obtuvieron datos agroclimáticos diarios del proyecto NASA POWER API [25] para los centroides geográficos distritales utilizando el cliente de R `nasapower` [26], los cuales se utilizaron directamente como representantes estacionales a nivel distrital (Tabla I). Los datos abarcan desde el 1 de enero de 2010 hasta el 31 de marzo de 2025. Se seleccionaron las siguientes variables:

Los valores diarios se agregaron a nivel de campaña (octubre a marzo) para alinearse con el ciclo fenológico de la quinua.

II-C. Modelo Estadístico

II-C1. Especificación del Modelo: Sea y_{ik} el rendimiento de quinua (kg/ha) para el distrito i durante la campaña k . Especificamos una distribución de verosimilitud Gaussiana:

$$y_{ik} \mid \mu_{ik}, \sigma^2 \sim \mathcal{N}(\mu_{ik}, \sigma^2) \quad (1)$$

Con el predictor lineal:

$$\begin{aligned} \mu_{ik} = & \alpha + \beta_1 z_{ik}^{\text{PREC}} + \beta_2 z_{ik}^{\text{TMIN}} \\ & + \beta_3 z_{ik}^{\text{RH}} + \beta_4 z_{ik}^{\text{RAD}} \\ & + \gamma_1 \log(\text{Siembras}_{ik}) + \gamma_2 \log(\text{Precio}_{ik}) \\ & + \delta_k + u_i \end{aligned} \quad (2)$$

Donde $z_{ik}^{(\cdot)}$ representa los predictores agroclimáticos estandarizados (con media cero y varianza unitaria), permitiendo la comparación directa de las magnitudes de los efectos.

II-C2. Efecto Espacial Aleatorio BYM2: El efecto espacial aleatorio $\mathbf{u} = (u_1, \dots, u_n)^\top$ sigue la parametrización BYM2 propuesta por [21]:

$$u_i = \frac{1}{\sqrt{\tau_{sp}}} \left[\sqrt{\phi} u_i^* + \sqrt{1 - \phi} v_i \right] \quad (3)$$

Donde u_i^* es el componente espacial estructurado regido por un proceso autorregresivo condicional intrínseco (ICAR), $v_i \sim \mathcal{N}(0, 1)$ es el componente espacial no estructurado (i.i.d.), $\phi \in [0, 1]$ es el parámetro de mezcla que controla la proporción de varianza espacial estructurada, y τ_{sp}^{-1} es la varianza marginal del efecto espacial. La vecindad espacial se construyó bajo el criterio de 5 vecinos más cercanos ($k = 5$) a partir de los centroides distritales promedio.

II-C3. Efecto Temporal Aleatorio AR(1): El componente temporal sigue un proceso autorregresivo de primer orden estacionario:

$$\delta_k = \rho \delta_{k-1} + \varepsilon_k, \quad \varepsilon_k \sim \mathcal{N}(0, \tau_t^{-1}(1 - \rho^2)) \quad (4)$$

Con $|\rho| < 1$ and varianza marginal $\delta_k \sim \mathcal{N}(0, \tau_t^{-1})$.

II-C4. Distribuciones Previas (Complejidad Penalizada): Siguiendo a [27], se asignaron distribuciones previas de Complejidad Penalizada (PC) a los hiperparámetros. Las previas PC se definen mediante la probabilidad límite $P(\text{parámetro} > U) = \alpha$, penalizando la desviación de los modelos más complejos hacia el modelo base simple:

$$\sigma \sim \text{PC}(500, 0.01) \quad (5)$$

$$\sigma_{sp} \sim \text{PC}(500, 0.01) \quad (6)$$

$$\phi \sim \text{PC-Beta}(0.5, 2/3) \quad (7)$$

$$\rho \sim \text{PC-Cor1}(0.97, 0.01) \quad (8)$$

$$\sigma_t \sim \text{PC}(500, 0.01) \quad (9)$$

$$\beta_p, \gamma_q \sim \mathcal{N}(0, 625) \quad (10)$$

II-C5. Inferencia (INLA): La estimación de los parámetros se realizó mediante la Aproximación de Laplace Anidada Integrada (INLA) [22], [23] utilizando el paquete R-INLA en el entorno de computación estadística R [28].

II-D. Comparación de Modelos

Los modelos ajustados se compararon utilizando el Criterio de Información de Watanabe-Akaike (WAIC), el Criterio de Información de Desviación (DIC) y la suma del logaritmo de las Ordenadas Predictivas Condicionales ($\sum \log \text{CPO}_i$), equivalente a la densidad de log-verosimilitud predictiva validada de forma cruzada (leave-one-out).

Cuadro I: Variables agroclimáticas obtenidas de la API NASA POWER y su agregación estacional para la campaña de crecimiento de quinua (octubre–marzo).

Código NASA	Descripción	Unidades	Agregación
PRECTOTCORR	Precipitación total corregida	mm día ⁻¹	Suma estacional
T2M_MIN	Temperatura mínima del aire a 2m	°C	Promedio estacional
RH2M	Humedad relativa a 2m	%	Promedio estacional
ALLSKY_SFC_SW_DWN	Irradiancia de onda corta incidente	kWh m ⁻² día ⁻¹	Promedio estacional

III. RESULTADOS

III-A. Estadísticas Descriptivas

El conjunto de datos final comprende $N = 1267$ observaciones estructuradas en panel (86 distritos en total a lo largo de 15 campañas agrícolas). Las estadísticas descriptivas de las variables bajo análisis se presentan en la Tabla II.

La Tabla III resume el rendimiento medio y los principales indicadores climáticos a nivel de provincia, agregados a partir de los datos distritales. Se observa que la provincia de Yunguyo registra el rendimiento medio más alto (1164 kg/ha) y la menor variabilidad relativa ($CV = 10.3\%$), mientras que Sandia, representada por una sola campaña productiva a escala distrital, exhibe el rendimiento más bajo (933 kg/ha).

La Figura 1 detalla la evolución del rendimiento provincial de quinua a lo largo de las 15 campañas. Se observa una tendencia general estable con una caída drástica y generalizada en la campaña 2022–2023 en todas las provincias, donde el rendimiento promedio descendió por debajo de 800 kg/ha debido a una sequía extrema y heladas asociadas al fenómeno de La Niña. Los diagramas de caja (Figura 1, panel inferior) muestran la dispersión interprovincial por período, evidenciando que la variabilidad interanual es de mayor magnitud que la heterogeneidad espacial transversal en años normales.

Por su parte, la Figura 2 expone la distribución espacial del rendimiento medio (2010–2025). Existe un gradiente latitudinal claro: las provincias del norte y centro adyacentes al Lago Titicaca, como Huanca-né, Yunguyo y Puno, registran rendimientos medios superiores a 1,150 kg/ha, favorecidas por el efecto de termorregulación hídrica del lago. En contraste, las provincias del sur y de mayor altitud (El Collao, Chucuito) y el oeste (Lampa) exhiben rendimientos significativamente menores (<1,000 kg/ha), evidenciando limitaciones climáticas y de suelo estructurales.

III-B. Diagnóstico de Colinealidad

Se evaluó la multicolinealidad entre los predictores antes de ajustar el modelo bayesiano mediante el Factor de Inflación de la Varianza (VIF) y la tolerancia (Tabla IV).

Todos los valores de VIF se mantuvieron por debajo del umbral conservador de 5.0, confirmando que la colinealidad no interfiere en la estimación del modelo, a pesar de que el número de condición ($\kappa = 14784.62$)

refleja la escala y variabilidad de las mediciones físicas a escala distrital.

La matriz de correlación de Spearman (Figura 3) revela asociaciones lineales y no lineales de interés. Se observa una correlación positiva moderada entre el rendimiento y la precipitación total ($\rho = 0.45$), así como con la temperatura mínima ($\rho = 0.38$), sugiriendo que la disponibilidad de agua y de energía térmica nocturna son los principales factores limitantes. La correlación negativa entre rendimiento y humedad relativa ($\rho = -0.32$) sugiere condiciones indirectas de presión de patógenos fúngicos.

Para desenredar la covarianza del sistema agroclimático, el Análisis de Componentes Principales (PCA) (Figura 4) muestra que los dos primeros componentes explican el 74.2 % de la variabilidad climática regional. El primer componente (Dim 1, 43.8 %) está dominado positivamente por la precipitación y la humedad relativa, y negativamente por la radiación solar, capturando el contraste entre campañas húmedas/nubladas y campañas secas/despejadas. El segundo componente (Dim 2, 30.4 %) refleja la variabilidad térmica nocturna, cargado fuertemente por la temperatura mínima.

III-C. Autocorrelación Espacial

El test de Moran para evaluar la autocorrelación espacial global del rendimiento a nivel distrital demostró una autocorrelación espacial positiva altamente significativa ($p < 0.05$) en 13 de las 15 campañas agrícolas analizadas (Tabla S1). Los índices de Moran fluctuaron entre 0.092 y 0.526 para las campañas significativas, evidenciando una fuerte estructuración espacial del rendimiento del cultivo en el altiplano. Las únicas campañas que no mostraron autocorrelación espacial significativa fueron 2018–2019 ($I = 0.0522$, $p = 0.1495$) y 2023–2024 ($I = 0.0148$, $p = 0.2931$). Esta fuerte autocorrelación espacial a nivel distrital contrasta notablemente con la ausencia de significancia a escala provincial (MAUP), lo cual justifica plenamente la incorporación del componente espacial BYM2 en el modelado espacio-temporal.

El análisis anual del Índice de Moran global (Figura 5) ratifica que, a escala provincial, no existe autocorrelación espacial significativa en ninguna de las campañas evaluadas. El índice fluctúa en valores cercanos a cero (entre -0.07 y 0.10), manteniéndose todos los p-valores muy por encima del umbral de 0.05. Como se discute en la Sección IV, la ausencia

Cuadro II: Estadísticas descriptivas de la variable dependiente (rendimiento de quinua) y de los predictores agroclimáticos y de control a nivel distrital en la región Puno (2010–2025). DE: desviación estándar.

Variable	N	Media	DE	Mín	Mediana	Máx
Rendimiento (kg ha ⁻¹)	1267	1077.6	165.3	320.0	1083.3	1595.3
PRECTOTCORR (mm)	1267	545.6	180.5	149.4	496.4	1750.4
T2M_MIN (°C)	1267	3.3	2.4	0.0	3.5	18.9
RH2M (%)	1267	67.0	6.8	55.5	65.1	90.8
ALLSKY_SFC_SW_DWN (kWh m ⁻² d ⁻¹)	1267	22.8	2.0	14.8	23.4	26.0
Superficie sembrada (ha)	1267	416.8	536.9	1.0	220.0	3711.0
Producción (t)	1267	435.7	585.3	1.0	230.0	4496.0
Precio Chacra (S/. kg ⁻¹)	1267	4.8	1.5	2.5	4.4	10.5

Cuadro III: Estadísticas agregadas de rendimiento y clima por provincia en el nivel distrital (Puno, 2010–2025).

Provincia	N obs	Distritos	Rend. Media	Rend. SD	CV (%)	Prec. media	T.min media
Yunguyo	82	6	1164	120	10.3	491	4.4
Putina	45	3	1148	175	15.2	499	2.2
Puno	209	14	1121	144	12.8	454	4.3
El Collao	30	2	1117	98	8.7	420	3.5
Lampa	119	8	1083	169	15.6	473	2.4
Huancané	106	8	1072	173	16.1	507	4.2
Melgar	133	9	1061	155	14.6	587	1.0
San Román	64	5	1054	197	18.7	471	3.8
Chucuito	105	7	1048	145	13.8	476	4.2
Carabaya	105	7	1045	110	10.5	971	4.3
Azángaro	208	14	1041	194	18.7	540	1.7
Moho	60	4	1035	191	18.4	623	5.2
Sandía	1	1	933	–	–	1125	4.9

Cuadro IV: Factor de Inflación de la Varianza (VIF) y tolerancia para los predictores del modelo distrital. $\kappa = 14784.62$ | $R^2 = 0.0903$. Un $VIF < 5$ indica colinealidad aceptable.

Variable	VIF	Tolerancia
PRECTOTCORR	4.516	0.221
T2M_MIN	1.077	0.929
RH2M	4.544	0.220
ALLSKY_SFC_SW_DWN	1.508	0.663
log(Siembras)	1.425	0.702
log(Precio Chacra)	1.013	0.987

de autocorrelación global es una consecuencia de la agregación a nivel provincial (MAUP).

III-D. Comparación de Modelos

Se evaluaron cuatro formulaciones alternativas mediante INLA. La Tabla V detalla los criterios de ajuste obtenidos.

El modelo M3, que incorpora tanto el componente espacial estructurado BYM2 como el temporal AR(1), proporciona el mejor ajuste, con una reducción sustancial del WAIC en comparación con las alternativas anidadas.

III-E. Efectos Fijos Agroclimáticos y de Control

Los resultados del modelo espacio-temporal completo (M3) se muestran en la Tabla VI.

Precipitación (z_{PREC}). Tiene un fuerte efecto positivo sobre el rendimiento ($\hat{\beta}_1 = 120.5$ kg/ha; IC del 95 %: [85.2, 155.8]), demostrando que el rendimiento

de la quinua está fuertemente limitado por el agua en el altiplano de Puno. Esto representa un efecto marginal de +0.668 kg/ha por cada milímetro adicional de lluvia estacional.

Temperatura mínima (z_{TMIN}). Ejerce un efecto positivo significativo ($\hat{\beta}_2 = 95.3$ kg/ha; IC del 95 %: [60.1, 130.5]). En el rango de temperaturas mínimas estacionales del altiplano, valores más altos reducen la frecuencia de heladas extremas, favoreciendo la productividad del cultivo.

Humedad relativa (z_{RH}). Tiene un efecto negativo significativo ($\hat{\beta}_3 = -65.4$ kg/ha; IC del 95 %: [-100.2, -30.6]). La alta humedad relativa favorece la proliferación del mildiu, la enfermedad fúngica más devastadora de la quinua.

Radiación solar (z_{RAD}). Afecta positivamente al rendimiento ($\hat{\beta}_4 = 45.1$ kg/ha; IC del 95 %: [15.3, 74.9]), evidenciando la importancia de la radiación solar para los procesos fotosintéticos y el llenado de grano.

Para visualizar las estimaciones de los efectos fijos, la Figura 6 presenta el gráfico de bosque (*forest plot*) con las medias posteriores y sus intervalos de credibilidad al 95 %. Los coeficientes estandarizados revelan que la precipitación estacional (z_{PREC}) es el principal factor promotor del rendimiento, seguida por la temperatura mínima (z_{TMIN}), mientras que la humedad relativa (z_{RH}) ejerce un claro efecto detractor.

Para apreciar el comportamiento en escala original, la Figura 7 ilustra las curvas de efecto marginal parcial para cada variable agroclimática, manteniendo las demás variables en sus valores medios. La curva de precipitación (Figura 7A) muestra un incremento lineal




Figura 1: Evolución temporal del rendimiento de quinua (kg/ha) por provincia en la región Puno (2010–2025) (panel superior) y distribución del rendimiento por campaña y período (panel inferior).

Cuadro V: Criterios de comparación de modelos bayesianos a nivel distrital. Valores menores de WAIC/DIC y mayores de log-CPO indican un mejor ajuste. El modelo M3 (completo) es el preferido.

Modelo	Descripción	WAIC	DIC	p_D	$\sum \log \text{CPO}$
M0	Nulo (BYM2 + AR1)	12450.2	12455.1	35.4	-4818.0
M1	Agroclimático + AR1	12105.4	12110.2	15.2	-4688.4
M2	M1 + Controles + AR1	11980.1	11984.8	18.5	-4645.5
M3	Completo (M2 + BYM2)	11340.5	11344.2	75.8	-4404.7

esperado en el rendimiento de +0.668 kg/ha por cada milímetro adicional de lluvia. La temperatura mínima (Figura 7B) indica que incrementos en la temperatura nocturna elevan el rendimiento a razón de +95.3 kg/ha por cada desviación estándar de aumento (lo que equivale a un efecto marginal de +40.2 kg/ha por °C). Por el contrario, incrementos en la humedad relativa (Figura 7C) deprimen el rendimiento esperado en −9.6 kg/ha por cada punto porcentual de humedad, mientras que la irradiancia solar (Figura 7D) muestra una pendiente positiva de +22.1 kg/ha por cada kWh/m²/día

de incremento.

III-F. Efectos Espaciales (BYM2)

El parámetro de mezcla espacial posterior $\hat{\phi} = 0.724$ (IC del 95 %: [0.551, 0.852]) indica que el 72.4 % de la variabilidad espacial residual está estructurada espacialmente (ICAR), sugiriendo patrones territoriales definidos. Los distritos del sur (provincia de Chucuito y El Collao) muestran efectos espaciales aleatorios sistemáticamente negativos, lo que revela un déficit de




Figura 2: Distribución espacial del rendimiento medio de quinua (kg/ha) por provincia de la región Puno durante el período 2010–2025.




Figura 3: Matriz de correlaciones de Spearman (ρ) entre las variables dependientes, agroclimáticas y de control del modelo provincial.

rendimiento que no se explica por las variables agroclimáticas observadas. Los distritos adyacentes al Lago Titicaca muestran efectos positivos, beneficiándose de la amortiguación térmica lacustre.

El mapa de las medias posteriores de los efectos espaciales aleatorios BYM2 (Figura 8) ilustra la heterogeneidad espacial latitudinal remanente tras controlar por el clima. Se aprecia un claro patrón espacial: los distritos del norte (Melgar, Azángaro, San Antonio de Putina) y los distritos centrales ribereños (Huancané, Puno) exhiben efectos espaciales positivos persistentes,

lo cual sugiere mejores condiciones edáficas y mayor adopción tecnológica. En contraposición, los distritos del extremo sur (El Collao y Chucuito) muestran déficits espaciales sistemáticos, reflejando una desventaja estructural que requiere intervenciones focalizadas.

III-G. Efecto Temporal Autorregresivo AR(1)

El parámetro posterior $\hat{\rho} = 0.452$ (IC del 95 %: [0.153, 0.721]) muestra una correlación moderada entre campañas consecutivas, capturando la inercia climática interanual del altiplano vinculada al fenómeno El Niño-




Figura 4: Análisis de Componentes Principales (PCA) de las variables agroclimáticas: gráfico de sedimentación (scree plot, izquierda) y biplot del primer y segundo componente (derecha).

Cuadro VI: Medias posteriores, desviaciones estándar (DE) e intervalos de credibilidad (IC) del 95 % para los parámetros del modelo distrital M3. Los efectos con asterisco (*) son significativos (su IC excluye el cero).

Parámetro	Media	DE	Q _{2.5}	Q _{97.5}	Sig.
Intercepto	1125.400	25.400	1075.600	1175.200	Sr*
<i>Efectos agroclimáticos (estandarizados)</i>					
zPREC (PRECTOTCORR)	120.500	18.200	85.200	155.800	Sr*
zTMIN (T2M_MIN)	95.300	17.800	60.100	130.500	Sr*
zRH (RH2M)	-65.400	17.500	-100.200	-30.600	Sr*
zRAD (ALLSKY_SFC_SW_DWN)	45.100	15.100	15.300	74.900	Sr*
<i>Efectos de control</i>					
log(Siembras)	30.200	10.100	10.400	50.000	Sr*
log(Precio Chacra)	15.400	9.800	-3.800	34.700	No
<i>Hiperparámetros</i>					
σ (residual)	152.500	7.700	138.700	169.000	Sr*
σ_{sp} (spatial)	110.400	5.400	101.000	122.200	Sr*
ϕ (spatial mixing)	0.724	0.076	0.551	0.852	Sr*
ρ (AR1 correlation)	0.452	0.145	0.153	0.721	Sr*
σ_t (temporal)	85.400	4.400	77.800	94.900	Sr*

* El intervalo de credibilidad al 95 % excluye el cero.




Figura 5: Índice de Moran global (I) por campaña agrícola a nivel provincial. Las barras grises denotan coeficientes no estadísticamente significativos ($p > 0.05$).

Oscilación del Sur (ENSO). Se identificaron efectos temporales negativos marcados en las campañas 2015–2016 y 2022–2023, periodos correspondientes a eventos El Niño intensos o sequías severas en el altiplano.

La trayectoria temporal estimada del proceso autorregresivo AR(1) se expone en la Figura 9. El coeficiente de persistencia $\hat{\rho} = 0.452$ confirma la inercia climática interanual. Los efectos temporales

muestran dos picos negativos profundos: la campaña 2015–2016 y la campaña 2022–2023 (donde el efecto descendió por debajo de -100 kg/ha), coincidiendo con eventos climáticos extremos de sequía severa en el altiplano andino bajo la influencia del ENSO, lo que demuestra la vulnerabilidad del rendimiento agrícola ante la variabilidad climática macro-regional.

III-H. Escenarios de Cambio Climático

A partir de la distribución posterior del parámetro de temperatura mínima, se proyectaron los cambios potenciales en el rendimiento medio de quinua ante diferentes niveles de calentamiento (Tabla VII).

Bajo un escenario de aumento de $+2^{\circ}\text{C}$ de temperatura mínima, se proyecta un incremento del 7.5 % ($+80.4$ kg/ha; IC del 95 %: $[50.7, 110.2]$ kg/ha) debido a la mitigación del riesgo de heladas, asumiendo que el suministro de agua por precipitación sea suficiente para suplir la mayor demanda hídrica.

La proyección de los cambios esperados en el rendimiento provincial ante escenarios hipotéticos de calentamiento nocturno de la temperatura mínima se muestra en la Figura 10. Se aprecia una relación positiva




Figura 6: Forest plot de los efectos fijos estimados (medias posteriores e intervalos de credibilidad del 95 % en escala estandarizada) para el modelo distrital M3.

Figura 9. Efectos marginales parciales distritales
Modelo M3 — Media posterior con IC 95% | Demás variables en su media




Figura 7: Curvas de efectos marginales parciales esperados del rendimiento de quinua (kg/ha) ante variaciones en la precipitación (A), temperatura mínima (B), humedad relativa (C) e irradiancia solar (D). Las áreas sombreadas indican intervalos de credibilidad al 95 %.

lineal en la respuesta del rendimiento medio, la cual proyecta incrementos desde +1.9 % (+20.1 kg/ha) en el escenario de +0.5°C hasta +11.2 % (+120.7 kg/ha) en el escenario extremo de +3.0°C, asumiendo la estabilidad del régimen de precipitaciones estacionales.

III-1. Validación del Modelo

El histograma de la Transformada Integral de Probabilidad (PIT) mostró una distribución aproximadamente uniforme, validando la calibración y el comportamiento predictivo del modelo. El test de Kolmogorov-Smirnov no rechazó la hipótesis nula de uniformidad ($D = 0.0297$, $p = 0.2134$), confirmando que la incertidumbre de la distribución predictiva del modelo M3 está correctamente calibrada.

La Figura 11 muestra el histograma de los valores PIT para el modelo final M3. Su distribución apro-

ximadamente uniforme y la cercanía de la densidad a la unidad (línea roja discontinua) validan probabilísticamente que el modelo está bien calibrado y no adolece de problemas graves de especificación. Esto es corroborado por el test de Kolmogorov-Smirnov ($D = 0.0297$, $p = 0.2134$).

Finalmente, los gráficos de diagnóstico de residuos (Figura 12) muestran la bondad de ajuste del modelo. El gráfico de residuos vs. valores predichos (Figura 12A) exhibe una nube homogénea de puntos sin patrones no lineales evidentes, indicando homocedasticidad y linealidad de los efectos. Por su parte, el QQ-plot (Figura 12B) muestra que los residuos se alinean firmemente a lo largo de la diagonal de normalidad teórica, excepto por desviaciones menores en las colas extremas.




Figura 8: Medias posteriores de los efectos espaciales aleatorios BYM2 por distrito (u_i , kg/ha). Los colores rojos denotan un déficit residual sistemático y los azules un superávit residual sistemático.




Figura 9: Efectos temporales aleatorios AR(1) por campaña agrícola (δ_k , kg/ha). La banda sombreada representa el intervalo de credibilidad al 95 %.

IV. DISCUSIÓN

IV-A. Factores Agroclimáticos Determinantes del Rendimiento

Los resultados confirmaron el papel dominante de la precipitación estacional como el principal determinante agroclimático del rendimiento de la quinua en el altiplano de Puno, en concordancia con hallazgos previos [7], [8]. El efecto marginal estimado (+120.5 kg/ha por DE, equivalente a +0.668 kg/ha por cada milímetro adicional de precipitación estacional) implica que un aumento de una desviación estándar en la precipitación incrementa el rendimiento en aproximadamente un 11.2 %, magnitud consistente con modelos de balance

hídrico de quinua en el altiplano [12] y consistente con estudios sobre la adaptación a la sequía andina [29].

El efecto de la temperatura mínima, altamente significativo, refleja una respuesta particular en el altiplano. Un incremento en la temperatura mínima estacional beneficia directamente al rendimiento al disminuir la frecuencia y la intensidad de los eventos de heladas nocturnas durante las fases vegetativas y reproductivas clave, disminuyendo el daño celular y el aborto de flores [10], [30]. La media posterior de +95.3 kg/ha por DE evidencia que la disponibilidad de calor térmico nocturno es crítica para estabilizar la productividad en este ambiente de gran altitud.

El efecto negativo de la humedad relativa concuerda

Cuadro VII: Impacto proyectado de escenarios de calentamiento de la temperatura mínima sobre el rendimiento medio de quinua en Puno. Rendimiento base: 1,077.6 kg/ha.

Escenario	ΔT (°C)	Δ Rend. (kg/ha)	IC bajo	IC alto	Cambio (%)
Línea base	0.0	0.0	0.0	0.0	0.0
+0.5°C	0.5	20.1	12.7	27.5	1.9
+1.0°C	1.0	40.2	25.4	55.1	3.7
+1.5°C	1.5	60.3	38.0	82.6	5.6
+2.0°C	2.0	80.4	50.7	110.2	7.5
+3.0°C	3.0	120.7	76.1	165.2	11.2




Figura 10: Proyección de los cambios absolutos en el rendimiento medio de quinua (kg/ha) bajo diferentes incrementos de temperatura mínima estacional. El área sombreada denota el intervalo de credibilidad al 95 %.




Figura 11: Histograma de los valores PIT (Probability Integral Transform) para el modelo distrital final M3. La línea discontinua roja indica la distribución uniforme teórica.

con las observaciones de campo sobre brotes de mildiu (*Peronospora farinosa*) en años húmedos. Este patógeno prospera bajo condiciones de alta humedad atmosférica y temperaturas moderadas [31], lo cual resalta la necesidad de desarrollar modelos de alerta temprana y manejo fitosanitario ante escenarios climáticos futuros que proyecten un incremento de la frecuencia de eventos extremos de lluvia.

IV-B. Estructura Espacial: Hallazgos del Componente BYM2 y Efectos del MAUP

Los efectos espaciales aleatorios significativos identificados por el modelo BYM2 revelan brechas sistemáticas de rendimiento que persisten tras controlar por los factores agroclimáticos observados. La concentración de efectos espaciales negativos en los distritos del

sur (provincia de Chucuito y El Collao) refleja probablemente una combinación de: (1) mayor incidencia de heladas locales por factores microclimáticos y topográficos no capturados por la resolución de NASA POWER [32]; (2) predominio de variedades locales tradicionales con menor potencial de rendimiento; y (3) menor tasa de adopción de prácticas agronómicas tecnificadas [33].

Desde una perspectiva metodológica, la transición de datos del nivel distrital al provincial introdujo cambios sustanciales en el análisis de autocorrelación espacial global. Mientras que a nivel distrital se reportaba autocorrelación espacial global estadísticamente significativa en la mayoría de campañas, a nivel provincial el test de Moran no rechazó la hipótesis nula de aleatoriedad espacial ($p > 0.05$). Este comportamiento ilustra el Problema de la Unidad de Área Modificable (MAUP) por agregación de zonas, donde el agrupamiento de unidades pequeñas suaviza las variaciones extremas y diluye el poder del estadístico global [34]. Sin embargo, la persistencia de patrones espaciales y el valor del parámetro de mezcla $\hat{\phi} = 0.724$ demuestran la necesidad de mantener el componente BYM2. La estructura espacial ICAR explica aproximadamente el 72.4 % de la varianza espacial residual, evidenciando la existencia de factores macro-regionales no observados fuertemente correlacionados en el espacio (tales como tipos de suelo o asistencia técnica regional).

IV-C. Dinámica Temporal e Influencia de ENSO

El coeficiente de autocorrelación temporal AR(1) $\hat{\rho} = 0.452$ (IC del 95 %: [0.153, 0.721]) captura la




Figura 12: Diagnóstico de residuos del modelo M3: residuos frente a valores predichos con ajuste local LOESS (A), y QQ-plot de normalidad de los residuos (B).

inercia climática interanual del altiplano. La identificación de efectos temporales negativos significativos en las campañas 2015–16 y 2022–23 coincide plenamente con los registros históricos del impacto de El Niño en la hidrología andina [8], [35], validando que las fluctuaciones del rendimiento en Puno están estrechamente articuladas a teleconexiones de gran escala como el ENSO.

IV-D. Implicaciones ante el Cambio Climático

La proyección del cambio en el rendimiento bajo el escenario de $+2^{\circ}\text{C}$ de calentamiento ($+80.4\text{ kg/ha}$, $+7.5\%$; IC del 95 %: $[50.7, 110.2]\text{ kg/ha}$) sugiere que el aumento de las temperaturas mínimas podría beneficiar la producción de quinua en el altiplano de Puno al atenuar las pérdidas por heladas. Sin embargo, esta proyección favorable asume que las lluvias estacionales no disminuyan y que el balance hídrico satisfaga la mayor demanda evaporativa del aire. Si el calentamiento se asocia con sequías más prolongadas, de acuerdo con los escenarios globales de cambio climático del IPCC [36], el estrés hídrico superará los beneficios térmicos, subrayando la urgencia de promover prácticas de cosecha de agua y riego tecnificado suplementario.

IV-E. Limitaciones del Estudio

Se deben reconocer algunas limitaciones. Primero, la resolución espacial de NASA POWER (cuadrícula de $0.5^{\circ} \times 0.5^{\circ}$) puede introducir errores de representatividad en terrenos montañosos complejos. Datos de mayor resolución espacial (como ERA5-Land a $\sim 9\text{ km}$) podrían refinar las estimaciones climáticas. Segundo, variables como las características del suelo, la variedad de quinua y el manejo agronómico no se incluyeron explícitamente debido a la falta de disponibilidad de datos consistentes a escala distrital. Tercero, aunque el supuesto de verosimilitud Gaussiana funcionó adecuadamente según la validación PIT, futuros trabajos podrían

explorar verosimilitudes log-normales o Gamma para el rendimiento distrital.

V. CONCLUSIONES

Este estudio desarrolló un modelo jerárquico bayesiano espacio-temporal para analizar la respuesta del rendimiento de quinua en el altiplano de Puno a nivel distrital (2010–2025). Las conclusiones principales son:

1. **La precipitación estacional es el factor determinante dominante** del rendimiento de quinua en Puno, con un efecto estimado de $+120.5\text{ kg/ha}$ por DE ($+0.668\text{ kg/ha}$ por cada milímetro adicional).
2. **El aumento de la temperatura mínima ejerce un efecto positivo y significativo** ($+95.3\text{ kg/ha}$ por DE) al mitigar la exposición a heladas estacionales en el altiplano.
3. **Existe una heterogeneidad espacial significativa no explicada** por factores climáticos ($\hat{\phi} = 0.724$), con distritos del sur (Chucuito, El Collao) mostrando un déficit sistemático de rendimiento que requiere políticas de extensión agraria focalizadas.
4. **La variabilidad interanual asociada al ciclo ENSO** se captura significativamente mediante el proceso AR(1) ($\hat{\rho} = 0.452$), evidenciando la utilidad de incorporar pronósticos climáticos en la planificación agrícola.
5. **Un escenario de calentamiento de $+2^{\circ}\text{C}$** proyecta un incremento del 7.5% en el rendimiento medio de quinua, condicionado a la disponibilidad de agua para el cultivo, mostrando que la adaptación hídrica es prioritaria ante el cambio climático.

REFERENCIAS

- [1] R. Repo-Carrasco-Valencia, C. Espinoza, and S.-E. Jacobsen, "Andean yams, quinoa and kañiwa: superfoods from the andes," *Food Reviews International*, vol. 19, no. 1–2, pp. 179–189, 2003.

- [2] D. Bazile, C. Pulvento, A. Verniau *et al.*, “A worldwide overview of cultivated quinoa: a call for the use of checks in a highly diverse crop,” *Frontiers in Plant Science*, vol. 7, p. 288, 2016.
- [3] N. Meza and C. Gómez, “Quinoa production in peru: economic and environmental challenges,” *Sustainability*, vol. 11, no. 18, p. 5055, 2019.
- [4] MIDAGRI, “Estadísticas agrarias – región puno: Hojas de seguimiento agrícola 2010–2025,” Ministerio de Desarrollo Agrario y Riego del Perú, Lima, Perú, Tech. Rep., 2024.
- [5] V.-H. Baldera-Chapoñan, G. De la Cruz, S. Oliva-Cruz, and F. Lozano-Isla, “Agromorphological characterization of quinoa (*Chenopodium quinoa* willd.) under andean–amazonian region of peru,” *Plants*, vol. 14, no. 23, p. 3689, 2025.
- [6] P. Olguín, S. Contreras, C. Rojas, and F. Fuentes, “Genotype-by-environment interaction stability analysis of new quinoa (*Chenopodium quinoa* willd.) varieties in the mediterranean zone of chile,” *Plants*, vol. 14, no. 19, p. 3007, 2025.
- [7] J. Quispe, F. Mamani, and W. Apaza, “Climatic variability and quinoa production in the puno altiplano,” *Scientia Agropecuaria*, vol. 11, no. 2, pp. 185–194, 2020.
- [8] W. S. Lavado Casimiro, J. Ronchail, D. Labat, J. C. Espinoza, and J. L. Guyot, “Impacts of climate variability and human activities on stream flow of an andean catchment,” *Water Resources Research*, vol. 47, no. 8, 2011.
- [9] H. D. Bertero, R. W. King, and A. J. Hall, “Effects of photoperiod, radiation and temperature on leaf and tiller production in quinoa (*Chenopodium quinoa* willd.) under field conditions,” *Field Crops Research*, vol. 86, no. 2-3, pp. 217–230, 2004.
- [10] J.-F. Bois, T. Winkel, J.-P. Lhomme, J.-P. Raffaillac, and A. Rocheteau, “Potential climatic change effects on the thermal growing conditions of the andean grains quinoa and lupin,” *Regional Environmental Change*, vol. 6, no. 3, pp. 96–104, 2006.
- [11] F. Razzaghi, F. Plauborg, S.-E. Jacobsen, C. R. Jensen, and M. N. Andersen, “Water relations and gas exchange of quinoa at various levels of water deficit,” *Agricultural Water Management*, vol. 108, pp. 112–120, 2012.
- [12] A. Zurita-Silva, E. Guzmán-Romero, and E. García-Soto, “Simulating quinoa growth in the bolivian altiplano with the crop model quicsim,” *Field Crops Research*, vol. 158, pp. 5–15, 2014.
- [13] L. Anselin, “Spatial econometrics: methods and models,” *Studies in Operational Regional Science*, vol. 4, 1988.
- [14] A. Gelman and J. Hill, *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge, UK: Cambridge University Press, 2006.
- [15] S. L. Jayasinghe and L. Kumar, “Forecasting global rice yield using machine learning and bayesian methods,” *Agricultural Systems*, vol. 176, p. 102613, 2019.
- [16] A. Ceglár, A. Tóreti, R. Lecerf, M. Van der Velde, and F. Dentener, “Pre-growing-season temperature strongly affects inter-annual variability of summer crops yield in central and western europe,” *Scientific Reports*, vol. 6, no. 1, p. 32193, 2016.
- [17] T. Iizumi and N. Ramankutty, “Responses of crop yield growth to global temperature and socioeconomic changes,” *Scientific Reports*, vol. 5, no. 1, p. 16345, 2018.
- [18] Y. Park, B. Li, and Y. Li, “Crop yield prediction using bayesian spatially varying coefficient models with functional predictors,” *Journal of the American Statistical Association*, vol. 118, no. 541, pp. 70–83, 2023.
- [19] M. S. A. Salan, M. M. Hossain, I. H. Sumon, M. M. Rahman, M. A. Kabir, and A. K. Majumder, “Measuring the impact of climate change on potato production in bangladesh using bayesian hierarchical spatial-temporal modeling,” *PLOS ONE*, vol. 17, no. 11, p. e0277933, 2022.
- [20] G. Leng and J. W. Hall, “Predicting spatial and temporal variability in crop yields: an inter-comparison of machine learning, regression and process-based models,” *Environmental Research Letters*, vol. 15, no. 4, p. 044027, 2020.
- [21] A. Riebler, S. H. Sørbye, D. Simpson, and H. Rue, “An intuitive bayesian spatial model for disease mapping that accounts for scaling,” *Statistical Methods in Medical Research*, vol. 25, no. 4, pp. 1145–1165, 2016.
- [22] H. Rue, S. Martino, and N. Chopin, “Approximate bayesian inference for latent gaussian models by using integrated nested laplace approximations,” *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 71, no. 2, pp. 319–392, 2009.
- [23] F. Lindgren and H. Rue, “Bayesian spatial modelling with r-inla,” *Journal of Statistical Software*, vol. 63, no. 19, pp. 1–25, 2015.
- [24] J. Ooms, “pdftools: Text extraction, rendering and converting of pdf documents,” *R package version 3.3.3*, 2022. [Online]. Available: <https://CRAN.R-project.org/package=pdfutils>
- [25] P. W. Stackhouse *et al.*, “Nasa power: Prediction of worldwide energy resources – the vision and the reality,” NASA Langley Research Center, Tech. Rep., 2019.
- [26] A. H. Sparks, “nasapower: a nasa power global meteorology, surface solar energy and climatology data client for r,” *Journal of Open Source Software*, vol. 3, no. 30, p. 1035, 2018.
- [27] D. Simpson, H. Rue, A. Riebler, T. G. Martins, and S. H. Sørbye, “Penalising model component complexity: a principled, practical approach to constructing priors,” *Statistical Science*, vol. 32, no. 1, pp. 1–28, 2017.
- [28] R Core Team, *R: A Language and Environment for Statistical Computing*, R Foundation for Statistical Computing, Vienna, Austria, 2024. [Online]. Available: <https://www.R-project.org/>
- [29] Q.-u. Ain, K. Siddique, S. Bawazeer, I. Ali, M. Mazhar, R. Rasool, B. Mubeen, F. Ullah, A. Unar, and T. H. Jafar, “Adaptive mechanisms in quinoa for coping in stressful environments: an update,” *PeerJ*, vol. 11, p. e14832, 2023.
- [30] I. Delfino-Yurin, J. Delatorre-Herrera, J. P. Rodríguez, J. P. Delatorre-Castillo, I. Sepúlveda-Soto, and C. Low-Pfeng, “Tolerance to occasional frosts during germination in chilean altiplano quinoa (*Chenopodium quinoa* willd.) cultivars,” *Frontiers in Plant Science*, vol. 16, p. 1718308, 2026.
- [31] S. Danielsen, A. Bonifacio, and T. Ames, “Quinoa downy mildew (*peronospora farinosa* f. sp. *chenopodii*) in south america,” *Plant Disease*, vol. 88, no. 4, pp. 327–334, 2004.
- [32] P. Mamani and W. Apaza, “Manejo integrado de la quinua en el altiplano peruano,” *Revista de Investigaciones Altoandinas*, vol. 14, no. 1, pp. 7–14, 2012.
- [33] W. Apaza, G. Cáceres, R. Estrada, and R. Pinedo, “Catálogo de variedades comerciales de quinua en el Perú,” *INIA/FAO*, 2013.
- [34] R. Bivand and D. W. Wong, “Comparing implementations of global and local indicators of spatial association,” *TEST*, vol. 27, no. 3, pp. 716–748, 2018.
- [35] J. Sulca, M. Vuille, Y. Silva, and K. Takahashi, “Impacts of different enso flavors and tropical pacific convection variability (itcz, spcz, and mjo) on austral summer rainfall in peru,” *Journal of Geophysical Research: Atmospheres*, vol. 123, no. 9, pp. 4718–4748, 2018.
- [36] IPCC, “Climate change 2021: The physical science basis,” Intergovernmental Panel on Climate Change, Cambridge, UK and New York, Tech. Rep., 2021.

APÉNDICE

Cuadro VIII: Estadístico Moran's I para la autocorrelación espacial del rendimiento de quinua por campaña agrícola a nivel distrital en Puno.

Campaña	Moran's I	p -valor	Significativo
2010-11	0.455	<0.001	Sí
2011-12	0.486	<0.001	Sí
2012-13	0.287	<0.001	Sí
2013-14	0.403	<0.001	Sí
2014-15	0.524	<0.001	Sí
2015-16	0.526	<0.001	Sí
2016-17	0.357	<0.001	Sí
2017-18	0.192	<0.001	Sí
2018-19	0.052	0.1495	No
2019-20	0.128	0.0135	Sí
2020-21	0.092	0.0480	Sí
2021-22	0.174	<0.001	Sí
2022-23	0.361	<0.001	Sí
2023-24	0.015	0.2931	No
2024-25	0.306	<0.001	Sí