

Patrones espaciales de la vegetación y su relación con factores climáticos y topográficos en la región Puno mediante índices espectrales y estadística espacial, 2025

Jose Carlos Iquise Pari, Julio Eduardo Maquera, Ruby Aymara, Hector Alan

Escuela Profesional de Ingeniería Estadística e Informática, Universidad Nacional del Altiplano, Puno, Perú

RESUMEN

Este estudio se integró índices espectrales de vegetación y técnicas de estadística espacial para caracterizar la cobertura vegetal de las 13 provincias de la región Puno durante el año 2025. Se analizaron el índice de vegetación de diferencia normalizada (NDVI), el índice ajustado al suelo (SAVI), el índice de vegetación mejorado (EVI) y el índice de humedad de diferencia normalizada (NDMI), junto con precipitación, temperatura, altitud y pendiente. La información provino de Sentinel-2, ERA5-Land y SRTM, fue procesada en Google Earth Engine y analizada en R. Después de excluir 114 puntos ubicados sobre superficies lacustres se conservaron 1385 observaciones terrestres. Se aplicaron estadística descriptiva, correlación de Spearman, Moran global, LISA, semivariogramas, Kriging ordinario, validación cruzada y modelos de regresión espacial. El NDVI promedio fue 0,380; Sandia (0,726) y Carabaya (0,538) registraron los valores provinciales más altos, mientras que El Collao presentó el menor (0,181). Los cuatro índices mostraron autocorrelación espacial positiva y significativa: NDVI = 0,874, EVI = 0,848, SAVI = 0,837 y NDMI = 0,792. El Kriging del NDVI alcanzó una correlación observada-predicha de 0,904 y RMSE de 0,112; SAVI obtuvo el menor RMSE entre los índices complementarios (0,075). La precipitación se relacionó positivamente con la vegetación, mientras que la altitud mostró una relación negativa. Para NDVI, el modelo de error espacial fue superior al modelo lineal y al SAR ($AIC = -2546,213$; $\lambda = 0,558$). Los resultados evidencian un gradiente norte-sur, con mayor vigor y humedad vegetal en Sandia y Carabaya y condiciones más limitantes en el altiplano central y sur.

Palabras clave— NDVI, SAVI, EVI, NDMI, LISA, Kriging.

Abstract— This study integrated spectral vegetation indices and spatial statistical techniques to characterize vegetation cover across the 13 provinces of the Puno region in 2025. NDVI, SAVI, EVI and NDMI were analyzed together with precipitation, temperature, elevation and slope. Data from Sentinel-2, ERA5-Land and SRTM were processed in Google Earth Engine and analyzed in R. After excluding 114 lake-surface points, 1385 terrestrial observations remained. Descriptive statistics, Spearman correlation, global Moran's I, LISA, variograms, ordinary Kriging, cross-validation and spatial regression were applied. NDVI showed the strongest spatial autocorrelation ($I = 0,874$). Kriging validation yielded a correlation of 0.904 and RMSE of 0.112 for NDVI, while SAVI achieved the lowest complementary-index RMSE (0.075). Sandia and Carabaya concentrated the highest vegetation and moisture values. The spatial error model best explained NDVI ($AIC = -2546.213$; $\lambda = 0,558$), confirming residual spatial dependence.

Keywords— NDVI, SAVI, EVI, NDMI, LISA, Kriging.

1. INTRODUCCIÓN

La observación de la Tierra mediante sensores ópticos permite evaluar la distribución y condición de la vegetación en áreas extensas con una frecuencia y consistencia difíciles de alcanzar mediante muestreos exclusivamente de campo. Los índices espectrales condensan la respuesta de diferentes bandas en medidas relacionadas con vigor, cobertura, estructura del dosel y contenido de humedad. Entre los índices más utilizados se encuentran NDVI, SAVI, EVI y NDMI, cada uno con sensibilidades y limitaciones particulares [1].

El NDVI resume el contraste entre el infrarrojo cercano y el rojo, y es ampliamente utilizado para describir actividad fotosintética y cobertura verde. Sin embargo, puede satu-

rarse en coberturas densas y verse afectado por el fondo del suelo. El SAVI incorpora un factor de ajuste que reduce ese efecto [2], mientras que el EVI mejora la sensibilidad en áreas de biomasa elevada y atenúa influencias atmosféricas y del suelo [3]. El NDMI, derivado de bandas del infrarrojo cercano y de onda corta, responde al contenido de agua en la vegetación y es útil para reconocer gradientes de humedad [4].

La región Puno presenta una marcada heterogeneidad ambiental. En distancias relativamente cortas coexisten zonas de selva alta, valles interandinos, mesetas altoandinas y áreas lacustres. Estas diferencias se traducen en fuertes gradientes de precipitación, temperatura, altitud y pendiente, por lo que el promedio regional puede ocultar agrupamientos territoriales relevantes. Sentinel-2 aporta

imágenes multiespectrales de alta resolución apropiadas para este tipo de evaluación [5]; ERA5-Land proporciona variables climáticas consistentes [6]; y SRTM permite representar la topografía regional [7].

Además de describir los valores de los índices, es necesario evaluar su dependencia espacial. Moran global permite determinar si observaciones similares se agrupan en el territorio [8], mientras que LISA identifica concentraciones locales y valores espacialmente atípicos [9]. Los semivariogramas y el Kriging permiten modelar la continuidad espacial y predecir valores en lugares no observados [10, 11]. Asimismo, los modelos SAR y SEM permiten incorporar explícitamente la dependencia espacial cuando la regresión convencional deja residuos autocorrelacionados [13, 14].

El objetivo fue integrar índices de vegetación, variables climáticas y topográficas con técnicas de estadística espacial para caracterizar los patrones provinciales de vegetación en Puno durante 2025. Se buscó: i) comparar NDVI, SAVI, EVI y NDMI entre provincias; ii) cuantificar su autocorrelación global y local; iii) interpolar superficies mediante Kriging y evaluar su precisión; iv) verificar la concordancia entre el muestreo puntual y el GeoTIFF original; y v) determinar la influencia de precipitación, altitud y pendiente sobre el NDVI mediante modelos espaciales.

2. MATERIALES Y MÉTODOS

2.1. Área de estudio, obtención y organización de los datos

El área de estudio comprendió las 13 provincias de la región Puno. La información fue construida en Google Earth Engine (GEE), plataforma que permite consultar, integrar y procesar colecciones geoespaciales a escala regional [15]. Para el componente espectral se emplearon imágenes de reflectancia superficial Sentinel-2 SR Harmonized correspondientes a 2025. Se utilizaron las bandas B2 (azul), B4 (rojo), B8 (infrarrojo cercano, NIR) y B11 (infrarrojo de onda corta, SWIR), compatibles con el cálculo de NDVI, SAVI, EVI y NDMI. Sentinel-2 fue seleccionado por su resolución espacial y disponibilidad multiespectral [5].

Las variables climáticas se obtuvieron de ERA5-Land: precipitación acumulada y temperatura media para el mismo periodo de análisis [6]. La altitud se obtuvo del modelo digital de elevación SRTM y la pendiente se derivó de esta superficie topográfica [7]. Los límites provinciales permitieron recortar las capas a Puno, asignar cada observación a una provincia y comprobar la coherencia territorial de las coordenadas.

El flujo de obtención siguió cinco etapas: i) delimitación de las provincias de Puno; ii) selección y preparación de las imágenes Sentinel-2 de 2025; iii) cálculo de los cuatro índices espectrales; iv) integración de precipitación, temperatura, altitud y pendiente; y v) exportación de los productos. Se generó el archivo raster multibanda `Indices_Clima_Topografia_Puno_2025.tif`, con ocho bandas y resolución de 100 m, así como la base puntual `Base_Puno_2025.csv`. Esta última incluyó provincia, longitud, latitud, NDVI, SAVI, EVI, NDMI, precipitación, temperatura, altitud y pendiente.

Todas las capas fueron proyectadas en WGS 84 / UTM

zona 19S (EPSG:32719). La base puntual inicial estuvo conformada por 1499 observaciones.

2.2. Formulación de los índices espectrales

Los índices se calcularon con reflectancias de superficie. El NDVI se obtuvo mediante

$$NDVI = \frac{\rho_{NIR} - \rho_{Red}}{\rho_{NIR} + \rho_{Red}}, \quad (1)$$

donde ρ_{NIR} y ρ_{Red} corresponden a B8 y B4, respectivamente [1].

El SAVI incorporó el factor de corrección del suelo $L = 0,5$ [2]:

$$SAVI = (1 + L) \frac{\rho_{NIR} - \rho_{Red}}{\rho_{NIR} + \rho_{Red} + L}. \quad (2)$$

El EVI se calculó con los coeficientes estándar $G = 2,5$, $C_1 = 6$, $C_2 = 7,5$ y $L = 1$ [3]:

$$EVI = G \frac{\rho_{NIR} - \rho_{Red}}{\rho_{NIR} + C_1 \rho_{Red} - C_2 \rho_{Blue} + L}, \quad (3)$$

donde ρ_{Blue} corresponde a B2.

Finalmente, el contenido relativo de humedad de la vegetación se representó mediante NDMI, equivalente a la formulación NIR-SWIR propuesta para agua líquida de la vegetación [4]:

$$NDMI = \frac{\rho_{NIR} - \rho_{SWIR}}{\rho_{NIR} + \rho_{SWIR}}, \quad (4)$$

donde ρ_{SWIR} corresponde a B11.

2.3. Validación espacial de los puntos

Durante la validación espacial se identificaron 114 puntos localizados principalmente sobre la superficie del lago Titicaca. Dado que estos registros no representan cobertura vegetal terrestre, fueron excluidos del análisis principal. La base final quedó conformada por 1385 puntos terrestres, mientras que los puntos sobre superficie acuática se conservaron únicamente como referencia cartográfica.




Figura 1: Validación espacial de la muestra.




Figura 2: Puntos Terrestres

2.4. Procesamiento y control de calidad

El análisis fue desarrollado en R. Se utilizaron estructuras vectoriales y raster estandarizadas mediante `sf` [12], `terra`, `spdep`, `spatialreg` y `gstat`. Se verificaron duplicados, datos faltantes, rangos físicos y consistencia de coordenadas. Para EVI se excluyeron píxeles raster fuera de $[-1, 1]$, asociados a denominadores espectrales inestables. Para estadísticas zonales, el raster se agregó de 100 m a 500

m con el fin de reducir el consumo de memoria sin perder representatividad a escala provincial.

2.5. Análisis descriptivo y correlacional

Se calcularon media, mediana, desviación estándar, mínimo y máximo para cada variable. Los promedios provinciales se estimaron tanto con el CSV como con el raster. Se aplicó correlación de Spearman debido a la presencia de asimetrías, valores extremos y relaciones potencialmente monotónicas no lineales.

2.6. Autocorrelación espacial

La matriz de pesos se construyó con los ocho vecinos más cercanos y estandarización por filas. Moran global se calculó para NDVI, SAVI, EVI y NDMI. Para NDVI se estimó Moran local y se clasificaron los puntos significativos ($p < 0,05$) en Alto-Alto, Bajo-Bajo, Alto-Bajo y Bajo-Alto.

2.7. Semivariograma, Kriging y validación

Se estimó un semivariograma experimental del NDVI con distancia máxima de 300 km e intervalos de 15 km. Se evaluaron modelos esférico, exponencial y gaussiano. Los modelos esférico y exponencial mostraron problemas de convergencia y rangos no plausibles; por ello se seleccionó el gaussiano, que representó de forma estable la tendencia experimental. El Kriging ordinario se aplicó sobre una malla de 5 km con 2697 ubicaciones. La precisión se evaluó mediante validación cruzada de 10 grupos usando error medio (ME), error absoluto medio (MAE), raíz del error cuadrático medio (RMSE) y correlación observada-predicha. El mismo procedimiento se aplicó a SAVI, EVI y NDMI.

2.8. Regresión espacial

Para NDVI se ajustó inicialmente una regresión múltiple con precipitación, temperatura, altitud y pendiente. Debido a la alta multicolinealidad entre temperatura y altitud (VIF superiores a 20), se retiró temperatura y se conservó precipitación, altitud y pendiente. Se emplearon errores robustos HC3. La autocorrelación residual se evaluó con Moran. Finalmente, se compararon el modelo lineal, el modelo de rezago espacial (SAR) y el modelo de error espacial (SEM) mediante AIC y log-verosimilitud.

3. RESULTADOS

3.1. Patrones descriptivos provinciales

El NDVI terrestre presentó una media de 0,380, mediana de 0,264, desviación estándar de 0,263 y rango entre -0,238 y 0,915. Los promedios provinciales mostraron un contraste marcado. Sandia registró el mayor NDVI medio (0,726), seguida por Carabaya (0,538). El Collao mostró el valor más bajo (0,181). SAVI y EVI reprodujeron el mismo orden general, mientras que NDMI fue positivo en Sandia (0,216) y Carabaya (0,047), pero negativo en la mayoría de las provincias altoandinas.

Provincia	<i>n</i>	NDVI	SAVI	EVI	NDMI
Sandia	261	0,726	0,426	0,471	0,216
Carabaya	248	0,538	0,310	0,337	0,047
San Antonio de Putina	67	0,296	0,179	0,175	-0,114
Huancané	52	0,279	0,182	0,179	-0,127
Melgar	96	0,265	0,165	0,161	-0,131
Puno	126	0,214	0,139	0,136	-0,115
El Collao	126	0,181	0,114	0,113	-0,122

Tabla 1: Promedios provinciales seleccionados.




Figura 3: Promedio de NDVI, SAVI, EVI y NDMI por provincia.

La dispersión interna fue mayor en Sandia y Carabaya, coherente con su diversidad altitudinal y ecológica. En Yunguyo, el promedio puntual fue menos estable porque el CSV contenía únicamente tres observaciones; por ello, para esa provincia el promedio raster ofrece una síntesis territorial más representativa.

3.2. Relaciones entre índices y variables locales

NDVI, SAVI y EVI mostraron relaciones muy altas entre sí: $\text{NDVI-SAVI} = 0,968$, $\text{NDVI-EVI} = 0,961$ y $\text{SAVI-EVI} = 0,997$. NDMI presentó asociaciones moderadas-altas con NDVI (0,636), SAVI (0,692) y EVI (0,694). La precipitación se relacionó positivamente con NDVI (0,698), mientras que la altitud presentó una correlación negativa (-0,689). Temperatura y altitud mostraron una asociación muy alta y negativa (-0,929), lo que justificó controlar su multicolinealidad en la regresión.




Figura 5: Matriz de correlación de Spearman entre índices y variables ambientales.

3.3. Autocorrelación espacial global y local

Todos los índices presentaron agrupamiento espacial positivo y altamente significativo (Tabla ??). El NDVI alcanzó el mayor Moran global (0,874), seguido por EVI (0,848), SAVI (0,837) y NDMI (0,792). Esto confirma que la distribución de la vegetación no es aleatoria y que los valores semejantes tienden a concentrarse geográficamente.

Índice	Moran <i>I</i>	<i>p</i>
NDVI	0,8745	< 0,001
SAVI	0,8370	< 0,001
EVI	0,8482	< 0,001
NDMI	0,7915	< 0,001

Tabla 2: Autocorrelación espacial global.

El LISA del NDVI clasificó 346 puntos como Alto-Alto y 228 como Bajo-Bajo; se detectaron además 5 Alto-Bajo, 7 Bajo-Alto y 799 no significativos. Los agrupamientos Alto-Alto se concentraron en el norte, especialmente en Sandia y sectores de Carabaya, mientras que los Bajo-Bajo se localizaron principalmente en el altiplano central y sur.




Figura 4: Distribución provincial de los cuatro índices de vegetación.




Figura 6: Clusters LISA del NDVI con ocho vecinos más cercanos.

3.4. Semivariograma e interpolación del NDVI

El semivariograma experimental aumentó progresivamente con la distancia. El modelo gaussiano seleccionado presentó efecto pepita de 0,0139, meseta parcial de 0,1068, meseta total de 0,1207 y rango de 193,2 km. La razón pepita/meseta total fue aproximadamente 11,5%, compatible con una dependencia espacial fuerte.




Figura 7: Semivariograma experimental del NDVI y modelo gaussiano ajustado.

La validación cruzada del NDVI produjo $ME = -0,0001$, $MAE = 0,0758$, $RMSE = 0,1124$ y correlación = 0,9042. El sesgo cercano a cero indica ausencia de sobreestimación o subestimación sistemática, mientras que la correlación elevada muestra que la superficie interpolada reproduce adecuadamente el patrón observado.

Índice	ME	MAE	RMSE	Correlación
NDVI	-0,0001	0,0758	0,1124	0,9042
SAVI	0,0000	0,0523	0,0753	0,8750
EVI	0,0001	0,0588	0,0875	0,8780
NDMI	0,0002	0,0698	0,1020	0,8630

Tabla 3: Validación cruzada del Kriging.

La superficie estimada confirmó el gradiente regional: valores altos hacia el norte y valores menores en las zonas central y sur. La varianza osciló aproximadamente entre 0,0140 y 0,0162, con una distribución relativamente uniforme, aunque aumentó en sectores periféricos con menor soporte muestral.

3.5. Interpolación de SAVI, EVI y NDMI

SAVI obtuvo el menor RMSE (0,0753), seguido por EVI (0,0875) y NDMI (0,1020). Los rangos ajustados fueron 189,2 km para SAVI, 180,5 km para EVI y 105,6 km para NDMI. El menor alcance del NDMI sugiere que la humedad vegetal cambia espacialmente a una escala más corta que el vigor o la cobertura verde.

3.6. Validación del muestreo con el GeoTIFF

El GeoTIFF de 100 m tuvo medias regionales de 0,3775 para NDVI, 0,2296 para SAVI, 0,2408 para EVI y -0,0316 para NDMI. La comparación de promedios provinciales entre el raster y el CSV produjo correlaciones de 0,9945, 0,9951, 0,9969 y 0,9870, respectivamente. Por tanto, el muestreo puntual conservó de manera muy alta la estructura provincial del raster original.

Índice	Correlación
NDVI	0,9945
SAVI	0,9951
EVI	0,9969
NDMI	0,9870

Tabla 4: Concordancia entre promedios raster.

3.7. Modelos explicativos del NDVI

El modelo lineal final, sin temperatura, explicó 84,6 % de la variación del NDVI ($R^2_{aj} = 0,8461$). La precipitación tuvo coeficiente positivo ($7,904 \times 10^{-5}$; $p < 0,001$), la altitud coeficiente negativo ($-1,227 \times 10^{-4}$; $p < 0,001$) y la pendiente no fue significativa con errores robustos ($p = 0,258$).

Sin embargo, los residuos conservaron autocorrelación espacial (Moran $I = 0,231$; $p < 0,001$), por lo que se ajustaron modelos SAR y SEM.

Modelo	AIC	logLik	Parámetro espacial
Lineal	-2351,744	1180,872	–
SAR	-2518,788	1265,394	$\rho = 0,478$
SEM	-2546,213	1279,107	$\lambda = 0,558$

Tabla 5: Comparación de modelos para NDVI.

El SEM fue el mejor modelo. En este, precipitación mantuvo un efecto positivo y altitud uno negativo; la pendiente adquirió un efecto pequeño pero significativo. El valor de λ confirmó dependencia espacial en factores no observados, como microclimas, tipo de cobertura, exposición o procesos ecológicos locales.

4. DISCUSIÓN

Los resultados describen una transición ambiental coherente con la diversidad regional de Puno. Sandia y Carabaya, ubicadas hacia el norte y con sectores de menor altitud, mayor temperatura y mayor precipitación, concentraron la vegetación más vigorosa y húmeda. En contraste, el altiplano central y sur presentó índices menores, compatibles con temperaturas bajas, elevaciones superiores y coberturas vegetales más abiertas.

La elevada correlación entre NDVI, SAVI y EVI confirma que los tres índices responden a un componente común de verdor y actividad fotosintética. No obstante, SAVI mostró el menor error de interpolación, lo que sugiere ventajas en ambientes donde el suelo expuesto puede afectar la señal. Esto es consistente con su diseño, orientado a disminuir la influencia del fondo edáfico [2]. EVI presentó un patrón cercano al NDVI, pero con una escala distinta, como se espera por sus correcciones y sensibilidad en coberturas densas [3].

NDMI mostró el menor Moran global y el rango geoestadístico más corto. Esta diferencia es importante: la humedad de la vegetación puede responder rápidamente a condiciones locales de suelo, exposición, precipitación reciente y drenaje, mientras que NDVI, SAVI y EVI reflejan componentes estructurales más persistentes. Por ello, NDMI no debe interpretarse únicamente como una repetición del patrón de verdor, sino como una dimensión complementaria de disponibilidad hídrica [4].

El alto Moran global de los cuatro índices demuestra que el uso de métodos espaciales era necesario. Ignorar esta dependencia habría producido errores estándar y relaciones incompletas. El LISA añadió una dimensión local al mostrar núcleos Alto-Alto y Bajo-Bajo, útiles para priorizar monitoreo, conservación o evaluación agroambiental. Sin embargo, los clusters representan asociación estadística y no deben interpretarse automáticamente como causalidad.

La validación del Kriging fue favorable. Para NDVI, el sesgo fue prácticamente nulo y la correlación superó 0,90. La varianza relativamente uniforme se relaciona con la distribución amplia de puntos, aunque la malla de 5 km




Figura 8: Kriging ordinario del NDVI e incertidumbre asociada.

suaviza patrones de escala fina. El rango gaussiano de 193 km debe entenderse como un parámetro del modelo ajustado y no como una frontera ecológica estricta. En estudios posteriores convendría comparar validación aleatoria con validación espacial por bloques, ya que la primera puede ser optimista cuando existe fuerte autocorrelación.

La concordancia superior a 0,98 entre CSV y GeoTIFF respalda la representatividad del muestreo. Aun así, la diferencia observada en Yunguyo demuestra que una asignación desigual de puntos puede afectar estimaciones provinciales. El raster zonal debe preferirse cuando la provincia posee pocos puntos, mientras que el CSV es adecuado para procedimientos que requieren observaciones puntuales y matrices de vecindad.

El modelo SEM del NDVI mejoró claramente el ajuste frente a la regresión lineal y al SAR. Esto sugiere que la dependencia espacial se concentra principalmente en el término de error, es decir, en variables omitidas con estructura geográfica. La precipitación positiva y la altitud negativa fueron relaciones robustas. La temperatura no se mantuvo en el modelo final por su fuerte colinealidad con la altitud; por tanto, el signo negativo observado en el modelo completo no debe interpretarse de manera aislada.

Entre las limitaciones se encuentran el uso de una síntesis anual, la exclusión de validación de campo, la distribución desigual del muestreo y la ausencia de variables como uso de suelo, tipo de vegetación, radiación, humedad del suelo y manejo agrícola. Además, el EVI requirió depuración de valores extremos del raster. Futuras investigaciones deberían analizar estacionalidad, incorporar parcelas de campo y ajustar modelos espacio-temporales.

5. CONCLUSIONES

La integración de teledetección y estadística espacial permitió caracterizar de manera consistente la vegetación de las provincias de Puno. Los cuatro índices mostraron fuerte autocorrelación positiva y patrones territoriales definidos. Sandía y Carabaya concentraron los valores más altos de vigor y humedad vegetal, mientras que El Collao y otras provincias del altiplano central y sur presentaron niveles menores.

El Kriging produjo superficies con buen desempeño predictivo. NDVI alcanzó una correlación de 0,904 y SAVI obtuvo el menor RMSE entre los índices complementarios. La concordancia entre el CSV y el GeoTIFF fue superior a 0,98, respaldando la representatividad del muestreo puntual.

La precipitación se asoció positivamente con NDVI y la altitud negativamente. El SEM fue el modelo explicativo más adecuado, confirmando que persisten factores espacialmente estructurados no incluidos en la regresión convencional. En conjunto, los resultados muestran que la vegetación de Puno debe analizarse como un fenómeno espacial heterogéneo y no solo mediante promedios regionales.

DISPONIBILIDAD DE DATOS, CÓDIGO Y REPRODUCIBILIDAD

El flujo de análisis fue implementado en RStudio. Los productos reproducibles incluyen la base depurada, los scripts de importación y limpieza, estadística descriptiva, Moran global y LISA, semivariogramas, Kriging, análisis del GeoTIFF y regresión espacial. El repositorio del proyecto se encuentra disponible en https://github.com/joiscarlip/Integracion_Indices_Puno. La dirección




Figura 9: Superficies interpoladas de SAVI, EVI y NDMI.

puede actualizarse en el archivo `main.tex` modificando únicamente el comando `\repoURL`. Por restricciones de tamaño y licencia, el GeoTIFF completo puede almacenarse mediante una versión publicada o un enlace de descarga independiente; el repositorio debe incluir, como mínimo, los scripts, el archivo README, las tablas finales y las figuras necesarias para reproducir el artículo.

REFERENCIAS

- [1] J. Xue and B. Su, “Significant remote sensing vegetation indices: A review of developments and applications,” *Journal of Sensors*, vol. 2017, pp. 1–17, 2017, doi: [10.1155/2017/1353691](https://doi.org/10.1155/2017/1353691).
- [2] A. R. Huete, “A soil-adjusted vegetation index (SAVI),” *Remote Sensing of Environment*, vol. 25, no. 3, pp. 295–309, 1988, doi: [10.1016/0034-4257\(88\)90106-X](https://doi.org/10.1016/0034-4257(88)90106-X).
- [3] A. Huete, K. Didan, T. Miura, E. P. Rodriguez, X. Gao, and L. G. Ferreira, “Overview of the radiometric and biophysical performance of the MODIS vegetation indices,” *Remote Sensing of Environment*, vol. 83, nos. 1–2, pp. 195–213, 2002, doi: [10.1016/S0034-4257\(02\)00096-2](https://doi.org/10.1016/S0034-4257(02)00096-2).
- [4] B.-C. Gao, “NDWI—A normalized difference water index for remote sensing of vegetation liquid water from space,” *Remote Sensing of Environment*, vol. 58, no. 3, pp. 257–266, 1996, doi: [10.1016/S0034-4257\(96\)00067-3](https://doi.org/10.1016/S0034-4257(96)00067-3).
- [5] M. Drusch *et al.*, “Sentinel-2: ESA’s optical high-resolution mission for GMES operational services,” *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012, doi: [10.1016/j.rse.2011.11.026](https://doi.org/10.1016/j.rse.2011.11.026).
- [6] J. Muñoz-Sabater *et al.*, “ERA5-Land: A state-of-the-art global reanalysis dataset for land applications,” *Earth System Science Data*, vol. 13, no. 9, pp. 4349–4383, 2021, doi: [10.5194/essd-13-4349-2021](https://doi.org/10.5194/essd-13-4349-2021).
- [7] T. G. Farr *et al.*, “The Shuttle Radar Topography Mission,” *Reviews of Geophysics*, vol. 45, no. 2, 2007, doi: [10.1029/2005RG000183](https://doi.org/10.1029/2005RG000183).
- [8] P. A. P. Moran, “Notes on continuous stochastic phenomena,” *Biometrika*, vol. 37, nos. 1–2, pp. 17–23, 1950, doi: [10.1093/biomet/37.1-2.17](https://doi.org/10.1093/biomet/37.1-2.17).
- [9] L. Anselin, “Local indicators of spatial association—LISA,” *Geographical Analysis*, vol. 27, no. 2, pp. 93–115, 1995, doi: [10.1111/j.1538-4632.1995.tb00338.x](https://doi.org/10.1111/j.1538-4632.1995.tb00338.x).
- [10] N. Cressie, “Fitting variogram models by weighted least squares,” *Mathematical Geology*, vol. 17, no. 5, pp. 563–586, 1985, doi: [10.1007/BF01032109](https://doi.org/10.1007/BF01032109).
- [11] E. J. Pebesma, “Multivariable geostatistics in S: The gstat package,” *Computers & Geosciences*, vol. 30, no. 7, pp. 683–691, 2004, doi: [10.1016/j.cageo.2004.03.012](https://doi.org/10.1016/j.cageo.2004.03.012).
- [12] E. Pebesma, “Simple features for R: Standardized support for spatial vector data,” *The R Journal*, vol. 10, no. 1, pp. 439–446, 2018, doi: [10.32614/RJ-2018-009](https://doi.org/10.32614/RJ-2018-009).
- [13] R. Bivand and G. Piras, “Comparing implementations of estimation methods for spatial econometrics,” *Journal of Statistical Software*, vol. 63, no. 18, pp. 1–36, 2015, doi: [10.18637/jss.v063.i18](https://doi.org/10.18637/jss.v063.i18).
- [14] J. LeSage and R. K. Pace, *Introduction to Spatial Econometrics*. Boca Raton, FL, USA: CRC Press, 2009, doi: [10.1201/9781420064254](https://doi.org/10.1201/9781420064254).
- [15] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau, and R. Moore, “Google Earth Engine: Planetary-scale geospatial analysis for everyone,” *Remote Sensing of Environment*, vol. 202, pp. 18–27, 2017, doi: [10.1016/j.rse.2017.06.031](https://doi.org/10.1016/j.rse.2017.06.031).